

Daniel Lubig  
E-Mail = daniel.lubig@tu-dresden.de

# Airport Operations - Anwendung zur Datenanalyse

Dresden, 19.05.2021

# Airport Operations - Anwendung zur Datenanalyse

## Installation von Software zur Nutzung von Python

**Fragen/Probleme bei der Installation?**

# Airport Operations - Anwendung zur Datenanalyse

## Python vs. Excel

### Python

Free-to-use + Standardsoftware zur Datenverarbeitung

Keine Software bedingten Limitierungen zur verwendeten Dateigröße

Schnelle Handhabung großer Datenmenge

Volle Kontrolle über alle Bildelemente

Kein direkter Zugriff auf Zellen

Aufwendige Veranschaulichung von Ergebnissen

### Excel

Schnelle Veranschaulichung der Ergebnisse

Direkter Zugriff auf Zellen

Kostenpflichtig (für nicht Studenten)

Begrenzt auf ~1,5 Millionen Datenzeilen

Lange Rechendauer für komplexe Berechnungen

Aufwendige Anpassung von Diagrammen

# Airport Operations - Anwendung zur Datenanalyse

## csv-Datensatz

- csv = comma-separated values
- kapazitätssparende Methode zur Speicherung größerer Datenmengen

Datensatz zur Übung → <https://github.com/DanielLubigTUD/AirportOperations2021>

### **Schritt 1: Umwandeln der csv-file in ein bearbeitungsfähiges Dateiformat**

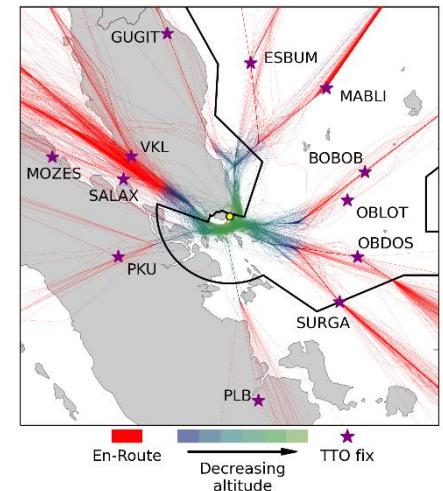
Excel → „Text in Spalten“

Python → Initiieren eines JupyterLab notebooks und Installation notwendiger python packages/librarys

# Airport Operations - Anwendung zur Datenanalyse

## Python package/librarys

- Sind nicht automatisch installiert → Installation/Importierung notwendig
- Speicherplatz niedrig halten



Name	Library or Package	Nutzung
Pandas	Library	Manipulation und Verarbeitung von Daten
Matplotlib	Library	Visualisierung von Daten
NumPy (Numerical Python)	Library	Handling von Matrizen, Vektoren und Arrays
SciPy (Scientific Python)	Library	Statistische Auswertung
SimPy (Simulation Python)	Library	Simulationsumgebung
Cartopy	Package	Erstellen von Karten

# Airport Operations - Anwendung zur Datenanalyse

## Installation/Import von packages/librarys

### Importierungsbefehl

```
import pandas as pd  
  
import numpy as np  
  
import matplotlib.pyplot as plt
```

### Installationsbefehl (nicht Teil dieser Übung)

#### COLAB

```
!apt-get -qq install python-cartopy python3-cartopy  
!pip install Cartopy
```

#### JupyterLab

```
!pip install Cartopy  
  
- Vorher weitere Schritte  
notwendig
```

# Airport Operations - Anwendung zur Datenanalyse

## Einlesen der csv-file als pandas DataFrame

### Einlesen der Dateien als DataFrame mithilfe von pandas:

Für csv-Dateien:

```
dataset_EDDM = pd.read_csv('Path on PC' or `web link`)
```

Für Excel-Dateien → pd.read\_excel('Path on PC' or `web link`)

Für pickle-Dateien → pd.read\_pickle('Path on PC' or `web link`)

### Informationen zum DataFrame:

```
dataset_EDDM.info()
```

### Ermittlung der Datentypen im Datenset:

```
dataset_EDDM.dtypes
```

- Übersicht zu Datentypen der einzelnen Spalten

# Airport Operations - Anwendung zur Datenanalyse

## wichtige Datentypen

Typ	Verwendung	Beispiel	Besonderheiten
String	Textbausteine	`Hallo`, `1`	Durch Anführungsstriche definiert
Integer	Ganze Zahlen	1	
Float	Kommazahlen	1.34	
Datetime/ Timestamp	Zeitpunkte	01.04.2019 12:34:23	können durch unterschiedliches Format definiert sein
Timedelta	Zeitdifferenzen	0 days 01:20:21	
Object	Kombination mehrerer Datentypen	23cdf563	Nicht für Berechnungen geeignet Ähnlichkeit mit Strings

- Python wandelt Datenformate automatisch um!

Bsp: float – integer = float **oder** timestamp – timestamp = timedelta

# Airport Operations - Anwendung zur Datenanalyse

## Umwandeln von Datentypen

### String

```
df['col'].astype(str)
```

df = Name des DataFrame  
col = Name der Spalte

### Float

```
df['col'].astype(float)
```

### Integer

```
df['col'].astype(int)
```

### Timestamp

```
pd.to_datetime(df['col'])
```

### Timedelta

```
pd.to_timedelta(df['col'])
```

# Airport Operations - Anwendung zur Datenanalyse

## Speichern des Datensatzes

### Als Excel-Datei speichern

```
df.to_excel('Path on PC.xlsx')
```

### Als csv-Datei speichern

```
df.to_csv('Path on PC.csv')
```

### Als Pickle-Datei (pkl) speichern

```
df.to_pickle('Path on PC.pkl')
```

- Schnelles einlesen der Daten
  - Speicherplatzsparend
  - Datentypen bleiben erhalten
- Nicht unabhängig von Programmiersprachen!

# Airport Operations - Anwendung zur Datenanalyse

## neue beste Freunde

### Stackoverflow

- Frage-Antwort Plattform für Programmierer

Link: <https://stackoverflow.com/>

### Github

- Kollaborative Entwicklungsplattform für Software

Link: <https://github.com/>

### Python interne Hilfefunktion

- Informationen zu Funktionen und deren Bestandteilen

JupyterLab: Funktionsname + ? → plt.savefig?

COLAB: ? + Funktionsname → ?plt.savefig

### Dokumentationen von librarys/packages

- Informationen zu Funktionen und deren Bestandteilen

Link: Google it!

# Airport Operations - Anwendung zur Datenanalyse

## Aufgabe 1 - Movements pro Tag im Datenzeitraum

Schritt 1: Zeitraum der Daten bestimmen (Start- und Enddatum)

Schritt 2: Alle Tage im Datenzeitraum als Liste ablegen

Schritt 3: Schleife zur Bestimmung der Bewegungen für jeden Tag initiieren

Schritt 3.1: Bestimmen der Grenzen eines Tages

Schritt 3.2: Filtern des Datensatzes nach Arrivals and Departures

Schritt 3.3: Alle Flüge innerhalb der Grenzen von Schritt 3.1 extrahieren

Schritt 3.4: Bestimmen der Anzahl der Starts und Landungen

Schritt 3.5: Speichern des Wertes in einem neuem DataFrame

Schritt 4: Bestimmen der Movements aus der Anzahl der Starts und Landungen

Schritt 5: Balkendiagramm zur Visualisierung erstellen

# Airport Operations - Anwendung zur Datenanalyse

## Aufgabe 2 – Verkehrsreichste Stunde ermitteln

IATA : „IATA defines the Peak Hour as the Busiest Hour in the second busiest day during the average week of the peak month; other authorities use the 30<sup>th</sup> busiest hour, etc.“

**2.A: 2nd busiest day → busiest hour**

**HAUSAUFGABE**

2.B: 30th busiest hour in the dataset

# Airport Operations - Anwendung zur Datenanalyse

## Aufgabe 2A – 30. verkehrsreichste Stunde ermitteln

Schritt 1: Zeitraum der Daten bestimmen (Start- und Enddatum)

Schritt 2: Alle Stunden im Datenzeitraum als Liste ablegen

Schritt 3: Schleife zur Bestimmung der Bewegungen für jede Stunde initiieren

Schritt 3.1: Bestimmen der Grenzen einer Stunde

Schritt 3.2: Filtern des Datensatzes nach Arrivals and Departures

Schritt 3.3: Alle Flüge innerhalb der Grenzen von Schritt 3.1 extrahieren

Schritt 3.4: Bestimmen der Anzahl der Starts und Landungen

Schritt 3.5: Speichern des Wertes in einem neuem DataFrame

Schritt 4: Bestimmen der Movements aus der Anzahl der Starts und Landungen

Schritt 5: Sortieren des Dataframes nach Movements (absteigend)

Schritt 6: Ermitteln der 30. verkehrsreichsten Stunde

# Airport Operations - Anwendung zur Datenanalyse

## Fehlersuche

- Python script läuft so lange bis ein „Error“ auftritt → Python Fehlermeldung taucht auf!
- Teilweise schwer verständliche Fehlermeldungen

**Tipp: Festlegen einer Testvariable oder Nutzung von Textblöcken zur Eingrenzung der fehlerhaften Codezeile**

`print('checkpoint1')` → Python gibt den Text aus, wenn bis zur Codezeile kein Fehler auftritt

`checkpoint = 1` → Python weist der Variable ‚checkpoint‘ den Wert 1 zu, wenn bis zur Stelle der Codezeile kein Fehler auftritt

→ die Variable kann nach Durchlauf des scripts ausgegeben werden

Daniel Lubig  
E-Mail = [daniel.lubig@tu-dresden.de](mailto:daniel.lubig@tu-dresden.de)

# Thanks for participation!

Dresden, 19.05.2021